

Programação Inteira, 2023.1

Relaxação Lagrangiana

DEMA/UFC

Entrada: problema (P)

Saída: solução inteira x^*

1. Iniciar estrutura de armazenamento de subproblemas:

$$Q = \{\emptyset\}$$

2. Enquanto $Q \neq \text{emptyset}$:

- Tome $s \in Q$
- $(z^R, x^R) := \text{relaxação}(P)$ satisfazendo s
- Se relaxação for inviável, continue
- Se $x^* \neq \emptyset$ e $z^R \leq z(x^*)$, senão continue
- Se x^R é solução inteira, considere atualizar x^* , senão:
 - Considere produzir solução inteira viável e atualizar x^*
 - Escolha x_j^R variável fracionária
 - $Q := Q \cup \{s \cup \{x_j \leq \lfloor x_j^R \rfloor\}, s \cup \{x_j \geq \lceil x_j^R \rceil\}\}$

3. Retorne x^* .

$$(P) \quad z = \max \quad c^\top x \quad (1)$$

s.a:

$$Dx \leq d \quad (2)$$

$$x \in X, \quad (3)$$

$$(LR(u)) \quad z(u) = \max \quad c^\top x + u^\top (d - Dx) \quad (4)$$

s.a:

$$x \in X. \quad (5)$$

$$(LD) \quad w_{LD} = \min\{z(u) : u \geq 0\}. \quad (6)$$

$$w_{LD} = \min_{u \geq 0} \left\{ \max \{ c^\top x^i + u^\top (d - Dx^i) : i = 1, \dots, t \} \right\}. \quad (7)$$

$$w_{LD} = \min \quad q \quad (8)$$

s.a:

$$q \geq c^\top x^i + u^\top (d - Dx^i), \quad i = 1, \dots, t \quad (9)$$

$$q \in \mathbb{R}, \quad u \in \mathbb{R}_+^m. \quad (10)$$

Um vetor $y \in \mathbb{R}^m$ é um subgradiente de uma função convexa f no ponto \bar{x} se

$$f(x) \geq f(\bar{x}) + y^\top (x - \bar{x}).$$

Vamos aplicar esta ideia à função $z(u)$.

Dado \hat{u} , seja \hat{x} a solução ótima de $(LR_{\hat{u}})$ com valor $z(\hat{u})$. Podemos afirmar que $y = d - D\hat{x}$ é um subgradiente de $z(u)$ no ponto \hat{u} :

$$\begin{aligned} z(\hat{u}) + y^\top (u - \hat{u}) &= z(\hat{u}) + (d - D\hat{x})^\top (u - \hat{u}) \\ &= c^\top \hat{x} + \hat{u}^\top (d - D\hat{x}) + (d - D\hat{x})^\top u - (d - D\hat{x})^\top \hat{u} \\ &= c^\top \hat{x} + (d - D\hat{x})^\top u \\ &\leq \max\{c^\top x + (d - Dx)^\top u : x \in X\} \\ &= z(u). \end{aligned}$$

1. Escolha u^0 como multiplicadores iniciais
2. Para $k = 0, \dots, K - 1$:
 - Resolver (LR_{u^k}) ; seja x^k a solução ótima e $z(u^k)$ seu valor
 - Calcular subgradiente $(d - Dx^k)$
 - Calcular passo $t^k = \frac{\lambda^k (z(u^k) + \underline{Z})}{\|Dx^k - d\|^2}$
 - Definir $u^{k+1} = [u^k + t^k (Dx^k - d)]_+$
- $0 < \lambda^k \leq 2$ é um parâmetro que tipicamente inicia como $\lambda^0 = 2$ e é reduzido pela metade sempre que o valor de $z(u^k)$ não é reduzido ao longo de certo número de iterações;
- A notação $[a]_+ = \max(a, 0)$ denota a “parte positiva” de a . No algoritmo, estamos nos certificando de que componentes negativas do vetor são substituídas por zero;
- \underline{Z} é um limite inferior para o valor ótimo de (P) , obtido, por exemplo, via uma heurística.

1. Como o dual lagrangeano é de minimização, calculamos u^{k+1} usando o subgradiente multiplicado por -1 , isto é, $(Dx^k - d)$ em vez de $(d - Dx^k)$.
2. A não ser que obtenhamos u^k tal que $z(u^k)$ seja igual ao valor de uma solução viável de (P) , não podemos provar a otimalidade de uma solução obtida pelo algoritmo de subgradientes.
3. Há certas garantias que asseguram a convergência do algoritmo (por exemplo, $\lim_{k \rightarrow \infty} t^k = 0$ e $\sum_{i=1}^k t^i \rightarrow \infty$) mas o algoritmo anterior que mostramos costuma apresentar melhor desempenho prático.
4. Se usarmos uma heurística para produzir soluções viáveis a partir da solução do problema relaxado, temos o que é chamado de uma *heurística lagrangiana*.